Архитектура DecoVAE-FM: Адаптация к парадигме Фундаментальных Моделей Временных Рядов

Техническая спецификация обновленной архитектуры

27 сентября 2026 г.

1 Обзор метода (Method pipeline)

Для решения задачи вероятностного прогнозирования временных рядов в рамках концепции фундаментальных моделей мы предлагаем архитектуру **DecoVAE-FM** — трёхпоточный вариационный автокодировщик (VAE) на базе трансформеров. Модель спроектирована для явного моделирования трендовой, сезонной и шумовой компонент с использованием структурно обоснованных индуктивных смещений:

- **гладкая латентная траектория** для тренда на основе патчей;
- **инвариантное частотное вариационное представление** для сезонности (Top-K гармоник);
- **остаточный шумовой поток** для residual после band-limited сезонной реконструкции.

Конвейер обработки DecoVAE-FM состоит из следующих этапов:

A) **Адаптивная мультимасштабная декомпозиция**: Входной ряд (после нормализации) разделяется на тренд и сезонность с помощью смеси сглаживающих фильтров с обучаемыми весами.

B) **Латентное моделирование компонент**: Трендовый поток токенизирует временную область патчами и кодирует совместную последовательность контекста и целевого горизонта (RoPE, prefix-mask). Сезонный поток переводит сигнал в частотную область, отбирает Top-K гармоник и проецирует их комплексным линейным слоем; по sparse-спектру строится band-limited реконструкция $\widehat{\mathbf{x}}_s$. Шумовой поток кодирует остаток $\mathbf{x} - \mathbf{x}_t - \widehat{\mathbf{x}}_s$ патч-трансформером (1 слой, 1 голова) с той же joint-схемой, что и тренд.

C) **Декодирование и наблюдение**: Тренд декодируется MLP с последующим Fold; сезонность — ComplexMLP, scatter коэффициентов на rFFT-бины (с пересчётом индексов на горизонт $T + L$) и iFFT. Параметры гауссовского наблюдения $\mathcal{N}(\mu, \sigma^2)$ собираются из суммы тренда и сезонности (среднее) и MLP-декодера дисперсии по конкатенации $[\mathbf{Z}_n; \overline{\mathbf{Z}}_s; \mathbf{Z}_t]$.

D) **Функция потерь**: Оптимизируется взвешенный отрицательный ELBO: гауссовский NLL реконструкции и прогноза плюс KL-дивергенции трендового, сезонного и шумового апостериоров к стандартным нормальным априорным распределениям.

1.1 Адаптивная декомпозиция

Дан одномерный ряд $\mathbf{x} \in \mathbb{R}^T$ (после asinh-нормализации по статистикам контекстного окна). Мультимасштабный блок декомпозиции со обучаемым вектором весов $\mathbf{w} \in \mathbb{R}^M$:

$$\mathbf{x}_{\text{trend}}^{(m)} = \text{AvgPool}_{\text{kernel}=k_m}(\mathbf{x}), \quad m \in \{1, \ldots, M\}, \tag{1}$$

$$\mathbf{w} = \text{Softmax}(\mathbf{w}_{\text{param}}) \in \mathbb{R}^M, \tag{2}$$

$$\mathbf{x}_t = \sum_{m=1}^{M} w_m \mathbf{x}_{\text{trend}}^{(m)}, \quad \mathbf{x}_s = \mathbf{x} - \mathbf{x}_t, \tag{3}$$

где набор k_m задаёт масштабы сглаживания (например, ядра длины 5, 9, 13, 25).

1.2 Латентное моделирование через Transformer-энкодеры

1.2.1 Трендовый поток с патчированием

Тренд $\mathbf{x}_t \in \mathbb{R}^T$ разбивается на N частично перекрывающихся патчей размера P с шагом S:

$$\mathbf{P}_n = \mathbf{x}_t[(n-1)S : (n-1)S + P] \in \mathbb{R}^P, \quad n = 1, \ldots, N. \tag{4}$$

Патчи проецируются в $\mathbb{R}^d$; позиционная информация задаётся RoPE в attention. Для горизонта L к контексту добавляются $N_{\text{target}} = \lceil L/S \rceil$ нулевых целевых токенов:

$$\mathbf{H}_0^{\text{trend}} = \left[\mathbf{P}_1\mathbf{W}_{\text{in}};\ \ldots;\ \mathbf{P}_N\mathbf{W}_{\text{in}};\ \mathbf{0};\ \ldots;\ \mathbf{0}\right] \in \mathbb{R}^{(N+N_{\text{target}})\times d}. \tag{5}$$

Совместная последовательность обрабатывается Transformer Encoder с prefix-маской (контекст не видит target; target видит весь контекст и все target-токены):

$$\mathbf{H}_{\text{trend}} = \text{TransformerEncoder}(\mathbf{H}_0^{\text{trend}}) \in \mathbb{R}^{(N+N_{\text{target}})\times d}. \tag{6}$$

Параметры гауссова апостериора:

$$\boldsymbol{\mu}_t = \text{Linear}_{\mu}(\mathbf{H}_{\text{trend}}) \in \mathbb{R}^{(N+N_{\text{target}})\times d}, \tag{7}$$

$$\log \boldsymbol{\sigma}_t^2 = \text{Linear}_{\log\sigma^2}(\mathbf{H}_{\text{trend}}) \in \mathbb{R}^{(N+N_{\text{target}})\times d}. \tag{8}$$

Сэмплирование латентного вектора:

$$\mathbf{Z}_t = \boldsymbol{\mu}_t + \boldsymbol{\sigma}_t \odot \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, I). \tag{9}$$

1.2.2 Сезонный поток в частотной области

Обозначим через $\mathcal{F}$ дискретное преобразование Фурье вещественного сигнала (rFFT), а через $\mathcal{F}^{-1}$ — обратное преобразование (irFFT). Тогда

$$\mathbf{X}_s^{(freq)} = \mathcal{F}(\mathbf{x}_s) \in \mathbb{C}^{K_{\text{orig}}}, \quad K_{\text{orig}} = \lfloor T/2 \rfloor + 1. \tag{10}$$

Отбираются K доминирующих гармоник (индексы бинов $\mathcal{I}$) и проецируются комплексным линейным слоем с ComplexGELU:

$$\mathbf{F}_{\text{tokens}} = \text{TopK}(\mathbf{X}_s^{(freq)}, K) \in \mathbb{C}^K, \tag{11}$$

$$\mathbf{H}_0^{\text{seas}} = \text{ComplexGELU}(\text{ComplexLinear}(\mathbf{F}_{\text{tokens}})) \in \mathbb{C}^{K\times d}. \tag{12}$$

Параметры комплексного нормального апостериора:

$$\boldsymbol{\mu}_s = \text{ComplexLinear}_{\mu}(\mathbf{H}_0^{\text{seas}}) \in \mathbb{C}^{K\times d}, \tag{13}$$

$$\log \boldsymbol{\sigma}_s^2 = \text{Linear}_{\log\sigma^2}([\Re(\mathbf{H}_0^{\text{seas}}), \Im(\mathbf{H}_0^{\text{seas}})]) \in \mathbb{R}^{K\times d}. \tag{14}$$

Сэмплирование латентного вектора:

$$\mathbf{Z}_s = \boldsymbol{\mu}_s + \sqrt{\frac{\boldsymbol{\sigma}_s^2}{2}} \odot (\boldsymbol{\epsilon}_r + i\,\boldsymbol{\epsilon}_i), \quad \boldsymbol{\epsilon}_r, \boldsymbol{\epsilon}_i \sim \mathcal{N}(0, I). \tag{15}$$

По спектру (только выбранные бины) строится реконструкция сезонности $\widehat{\mathbf{x}}_s = \mathcal{F}^{-1}(\mathrm{Scatter}(\mathbf{F}_{\mathrm{tokens}}, \mathcal{I}))$, используемая для выделения шума.

1.2.3 Шумовой поток

Остаток $\mathbf{x}_n = \mathbf{x} - \mathbf{x}_t - \widehat{\mathbf{x}}_s$ кодируется аналогично тренду: патчирование, RoPE-трансформер с prefix-маской и контекстными/таргет токенами (по умолчанию 1 слой, 1 голова). Параметры апостериора $\boldsymbol{\mu}_n, \log \boldsymbol{\sigma}_n^2$ и сэмпл $\mathbf{Z}_n$ имеют ту же форму, что и в трендовом потоке.

1.3 Декодирование и модель наблюдения

Среднее тренда декодируется MLP по латентным патчам с последующим выравниванием на длину $T + L$:

$$\widehat{\boldsymbol{\mu}}_t = \mathrm{Fold}(\mathrm{MLP}_{\mathrm{trend}}(\mathbf{Z}_t)) \in \mathbb{R}^{T+L}. \tag{16}$$

Сезонное среднее — ComplexMLP, декодированных коэффициентов на rFFT-бины длины $T + L$ (индексы $\mathcal{I}$ пересчитываются так, чтобы сохранить физическую частоту k/T) и iFFT:

$$\widehat{\boldsymbol{\mu}}_s = \mathcal{F}^{-1}(\mathrm{Scatter}(\mathrm{ComplexMLP}(\mathbf{Z}_s), \mathcal{I}')) \in \mathbb{R}^{T+L}. \tag{17}$$

Логарифм дисперсии наблюдения предсказывается MLP по конкатенации шумовых и трендовых токенов с усреднённым сезонным латентом $[\Re\mathbf{Z}_s, \Im\mathbf{Z}_s]$, затем Fold:

$$\log \boldsymbol{\sigma}^2 = \mathrm{Fold}\big(\mathrm{MLP}_{\log \sigma^2}([\mathbf{Z}_n; \overline{\mathbf{Z}}_s; \mathbf{Z}_t])\big) \in \mathbb{R}^{T+L}. \tag{18}$$

Итоговое наблюдение:

$$p(\mathbf{x} \mid \mathbf{Z}_t, \mathbf{Z}_s, \mathbf{Z}_n) = \mathcal{N}\big(\widehat{\boldsymbol{\mu}}_t + \widehat{\boldsymbol{\mu}}_s,\ \mathrm{diag}(\boldsymbol{\sigma}^2)\big). \tag{19}$$

Контекст и прогноз — срезы длины T и L соответственно: $\widehat{\mathbf{x}}$, $\widehat{\mathbf{y}}$ и $\log \boldsymbol{\sigma}^2_{\mathrm{recon}}$, $\log \boldsymbol{\sigma}^2_{\mathrm{forecast}}$.

1.4 Функция потерь

Обучение ведётся на нормализованном контексте $\mathbf{x} \in \mathbb{R}^T$ и будущем $\mathbf{y} \in \mathbb{R}^L$. Отрицательный ELBO:

$$\mathcal{L} = w_r\, \mathcal{L}_{\mathrm{NLL}}(\mathbf{x}; \widehat{\mathbf{x}}, \log \boldsymbol{\sigma}^2_{\mathrm{recon}}) + w_f\, \mathcal{L}_{\mathrm{NLL}}(\mathbf{y}; \widehat{\mathbf{y}}, \log \boldsymbol{\sigma}^2_{\mathrm{forecast}}) + \beta\,(\mathcal{L}_{KL}^{trend} + \mathcal{L}_{KL}^{seas} + \mathcal{L}_{KL}^{noise}), \tag{20}$$

где

$$\mathcal{L}_{\mathrm{NLL}}(\mathbf{u}; \boldsymbol{\mu}, \log \boldsymbol{\sigma}^2) = \frac{1}{2}\,\mathrm{mean}\Big(\log(2\pi) + \log \boldsymbol{\sigma}^2 + (\mathbf{u} - \boldsymbol{\mu})^2 \odot e^{-\log \boldsymbol{\sigma}^2}\Big), \tag{21}$$

а $\mathcal{L}_{KL}^{seas}$ считается в комплексном латентном пространстве относительно $\mathcal{CN}(0, I)$.

При инференсе сэмплы берутся из модели наблюдения $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2)$ (после латентного сэмплирования) и денормализуются.

2 TODO

- Добавить рандомное маскирование, т.е. случайно отключать различные значения ряда.